

Relatório:

Classificação de Sentimentos e Análise Comparativa

Etapa 1: Carga dos dados e tratamentos

Auditoria Inicial do Dataset

Antes do pré-processamento, o dataset passou por uma auditoria de qualidade. Foram extraídos 206.952 registros no total. Não foram encontrados ratings inválidos nem IDs duplicados. Contudo, 4.167 registros foram removidos por conterem texto vazio, resultando em um dataset limpo para análise.

Distribuição e Classificação dos Dados

Após a limpeza, os registros com rating 3 (neutro) foram excluídos por não apresentarem polaridade clara, restando 197.095 avaliações. Os ratings 1 e 2 foram mapeados como negativos, e os ratings 4 e 5 como positivos, gerando a seguinte distribuição binária: 9.973 registros negativos e 187.122 registros positivos.

Vale destacar o forte desbalanceamento de classes: avaliações positivas representam aproximadamente 95% do dataset, o que deve ser considerado nas etapas de modelagem.



Distribuição por Rating e Classe

Rating	Negativo	Positivo
1	7.196	0
2	2.777	0
4	0	12.571
5	0	174.551
Total	9.973	187.122

Exemplos de Registros

ID	Rating	Classe	Texto
reviews_mercadolivre_com_br_2.json::45490	5	Positivo	"Recomendo amei."
reviews_mercadolivre_com_br_2.json::78071	5	Positivo	"Bom."
reviews_mercadolivre_com_br_2.json::100816	5	Positivo	"Adorei! Meu cabelo ficou muito macio e brilhante, o cheiro é maravilhoso. "
reviews_mercadolivre_com_br_2.json::92520	2	Negativo	"Muito caro sem efeito."
reviews_mercadolivre_com_br_1.json::10358	5	Positivo	"Ótimo."

Gráfico da distribuição:



Etapa	Quantidade
Extração padronizada	206.952
Após limpeza básica	197.095
Após remoção do rating 3	197.095
Negativos (antes do balanceamento)	9.973
Positivos (antes do balanceamento)	187.122

- O rating 5 foi o mais frequente entre as notas originais válidas.
- O rating 4 foi a menor classe nas notas originais.
- Após o descarte do rating 3, a base binária ficou exatamente balanceada.
- A proporção dos ratings dentro de cada classe foi mantida.

Distribuição após o Undersampling

Após aplicar undersampling na classe positiva, o dataset foi balanceado, contendo agora 9.973 registros para cada classe. A distribuição final é perfeitamente equilibrada:

Classe	Quantidade
Negativo	9.973
Positivo	9.973
Total	19.946

Rótulos Binários Finais

Os rótulos foram convertidos para a representação binária definitiva (0 = negativo, 1 = positivo), mantendo o equilíbrio:

Rótulo	Classe	Quantidade
0	Negativo	9.973
1	Positivo	9.973

Total	—	19.946
--------------	---	---------------

Tamanho dos Conjuntos Oficiais

O dataset balanceado foi dividido em três conjuntos oficiais para treinamento e avaliação do modelo:

Conjunto	Tamanho
Treino	15.956
Validação	1.995
Teste	1.995
Total	19.946

Distribuição Absoluta por Classe em Cada Conjunto

Conjunto	Tamanho	Negativos	Positivos
Treino	15.956	7.978	7.978
Validação	1.995	997	998
Teste	1.995	998	997

- Treino: usado para aprender os padrões dos dados.
- Validação: usado para ajustar decisões do modelo e acompanhar o desempenho durante o desenvolvimento.
- Teste: usado apenas na avaliação final, para estimar o desempenho real em dados não vistos.

A divisão manteve o balanceamento perfeito entre as classes em todos os conjuntos, com proporções próximas de 50% para cada rótulo, garantindo avaliação justa do modelo.

Treinamento dos modelos de regressão para o TF-IDF

- TfidfVectorizer: transforma o texto em números.
 - Parameters: mostra os parâmetros definidos.
 - Fitted attributes: mostra o que foi aprendido na etapa.
- 13638 features: quantidade de atributos gerados.
- LinearSVC: classificador final.
 - Parameters: parâmetros do classificador.
 - Fitted attributes: parâmetros aprendidos no treinamento.

Avaliação dos modelos:


Modelo	Acurácia	Precision (macro)	Recall (macro)	F1 (macro)
Reg. Logística (validação)	0.933835	0.934222	0.933842	0.933821
Reg. Linear SVM (validação)	0.933333	0.933405	0.933337	0.933331

Selecionamos o modelo de Regressão Logística por obter uma melhor performance por se tratar de um problema binário e de classificação.

Classe	Precision	Recall	F1-Score	Support
Negativo	0.95	0.95	0.95	998
Positivo	0.95	0.95	0.95	997

accuracy	—	—	0.95	1995
macro avg	0.95	0.95	0.95	1995
weighted avg	0.95	0.95	0.95	1995

- 950 negativos foram classificados corretamente.
- 948 positivos foram classificados corretamente.
- 48 Falsos positivos.
- 49 Falsos negativos.
- Os acertos ficaram próximos nas duas classes, indicando equilíbrio.
- O número de erros foi baixo, sugerindo bom desempenho geral.
- Acurácia e F1-Score próximo de 0.95



Etapa 2: Fine-tuning com BERTimbau

Modelo BERT Utilizado

O modelo BERT empregado foi o **neuralmind/bert-base-portuguese-cased**, específico para português.

Tamanhos dos Conjuntos de Treinamento (BERTimbau)

Os conjuntos de validação e teste do BERT foram mantidos idênticos aos do notebook TF-IDF.


Métricas do Modelo BERTimbau (Conjunto de Validação)

Modelo	Acurácia	Precision (macro)	Recall (macro)	F1 (macro)
BERTimbau	0.964912	0.964957	0.964915	0.964912

O BERTimbau atingiu 96,49% de acurácia na validação, superando os modelos baseados em TF-IDF (Regressão Logística: 93,38% e Linear SVM: 93,33%). Todas as métricas (precision, recall e F1) estão consistentemente acima de 0.964, indicando desempenho robusto e equilibrado entre as classes.

Classe	Precision	Recall	F1-Score	Support
Negativo	0.97	0.96	0.96	998
Positivo	0.96	0.97	0.97	997
accuracy	—	—	0.96	1995
macro avg	0.96	0.96	0.96	1995
weighted avg	0.96	0.96	0.96	1995


- 958 avaliações negativas foram classificadas corretamente.
- 967 avaliações positivas foram classificadas corretamente.
- 40 Falsos positivos.
- 30 Falsos negativos.
- O modelo apresenta alto desempenho geral, com maioria expressiva de acertos.
- Há poucos erros nas duas classes, indicando boa consistência.
- O número de erros é menor para positivos do que para negativos.
- A matriz sugere boa capacidade de generalização do BERTimbau.
- Acurácia e F1-Score próximo de 0.97



Etapa 3: Comparação quantitativa entre as abordagens

- BERTimbau supera a Regressão Logística em todas as métricas, porém por apenas ~1,42%.
- Ambos os modelos apresentam desempenho elevado, com acurácia acima de 95%.
- A Regressão Logística, mesmo sendo um modelo mais simples, obteve resultados muito próximos aos do BERT.
- A margem de vantagem do BERT é pequena, o que sugere que o TF-IDF + Regressão Logística é uma alternativa competitiva para essa tarefa.

Modelo	Acurácia	Precision (macro)	Recall (macro)	F1 (macro)	Tamanho do Teste
BERTimbau	0.964912	0.964957	0.964915	0.964912	1.995
Regressão Logística	0.951378	0.951379	0.951378	0.951378	1.995



Casos em que TF-IDF erra e BERT acerta: 53


Casos em que BERT erra e TF-IDF acerta: 26

Casos divergentes totais: 79

Rating	Texto	Classe Real	TF-IDF	BERT
5	"Alisa 100%."	Positivo	Negativo	Positivo
5	"Muito, não é pegajoso e não sai fácil na água."	Positivo	Negativo	Positivo
1	"Não tenho muito o que falar sobre o produto não usei ainda mas o cheiro é bem forte."	Negativo	Positivo	Negativo

Rating	Texto	Classe Real	TF-IDF	BERT
2	"Pro."	Negativo	Negativo	Positivo
1	"Normal."	Negativo	Negativo	Positivo
2	"Comecei a tomar ontem, então não tem como eu avaliar ainda daqui há algumas semanas com fé em deus eu observo o resultado."	Negativo	Negativo	Positivo

Padrão observado: O BERT tende a interpretar palavras ambíguas como "Pro." e "Normal." ou textos com linguagem neutra/esperança como positivos, enquanto o TF-IDF captura melhor a classificação negativa baseada em ratings baixos.



Os resultados de bootstrap indicam vantagem do BERTimbau sobre o TF-IDF + Regressão Logística no teste de 1.995 instâncias, com diferença média de 1,36 pontos percentis e com intervalo de confiança de 95% inteiramente positivo [0,45% , 2,26%]. Ainda assim, há sobreposição entre as distribuições amostrais, de modo que o TF-IDF pode superar o BERT em algumas reamostragens.

Modelo	Média (IC 95%)	Inf 95%	Sup 95%
TF-IDF + Regressão Logística	0,951325	0,941353	0,960902
BERTimbau	0,964970	0,956391	0,972932
Diferença (BERT – TF-IDF)	0,013644	0,004511	0,022556

Conclusões:

TF-IDF

O modelo baseado em TF-IDF (com Regressão Logística) apresenta as seguintes características:

- Mais simples, rápido e barato de treinar: Requer menos recursos computacionais e tempo de treinamento.
- Bom como baseline e mais fácil de interpretar: As características (words) são diretamente interpretáveis.
- Funciona muito bem quando o texto é mais direto: Captura bem padrões de palavras-chave explícitas.
- Tem mais dificuldade com contexto, ambiguidade e negação mais complexa: Não compreende bem o significado contextual das palavras.
- Utilizar quando velocidade e simplicidade são prioridade: Ideal para projetos com restrições de recursos.

BERTimbau

O modelo BERTimbau apresenta as seguintes características:

- Teve o melhor resultado geral: Superou o TF-IDF em acurácia, precision, recall e F1-score.
- Captura melhor o contexto e nuances do português: Compreende o significado contextual e semântico das palavras.
- Acertou mais casos difíceis que o TF-IDF: Especialmente em textos com negações, linguagem implícita e ambiguidade.

- Exige mais processamento e é menos interpretável: Requer GPUs/TPUs e o modelo é um "black box".
- Utilizar quando máxima acurácia é prioridade: Ideal para aplicações críticas onde a precisão é fundamental.

Recomendação Final

A escolha entre os modelos depende do objetivo do projeto:

- Para projetos com restrições de recursos, necessidade de rapidez ou interpretabilidade: utilizar TF-IDF.
- Para aplicações críticas onde máxima acurácia é fundamental e há recursos computacionais disponíveis: utilizar BERTimbau.